

## EPnP 算法整理

EPnP 作为 PnP 算法的一种，与常见的求解参考点深度方案不同，如图 1 所示，用控制点的加权和来表示  $n$  个参考点，通过求解 4 个非共面的控制点（平面场景下需要 3 个控制点）的深度来减小计算量，进而计算参考点在相机坐标系下的坐标。在求解过程中，为减小计算量，使用一个  $12 \times 12$  矩阵的零特征向量的加权和来求解；再通过以求解二次方程的小常数解的方式来选择合适的权重。之后将求得的封闭解作为 Gaussian-Newton 法的初值进行优化，得出更加精确的结果。

在解算过程中，EPnP 算法只需求解控制点的深度，而无需单独计算每个参考点，故而大大地提升了效率。




图 1 通过控制点求解 EPnP

### 一. 算法步骤（思路）

对于所给定的  $n$  个参考点  $p_i, i = 1, \dots, n$ ，已知其 3D 世界坐标  $p_i^w$  和 2D 图像投影，投影坐标为  $u_i$ 。首先确定合适的控制点  $c_j$  和权值  $\alpha_{ij}$ ；之后由相机坐标系和像素坐标系之间的转化关系列写线性方程组。

$$s_i \begin{bmatrix} u_i \\ 1 \end{bmatrix} = K p_i^c = K \sum_{j=1}^4 \alpha_{ij} c_j^c$$

每个参考点可以提供 2 个方程约束，这样就可以得到  $2n$  个方程组成的方程组，其中未知数数目为 12（每个控制点的 3D 坐标，共 4 个控制点）。将方程组转化为矩阵的形式

$$Mx = 0$$

其中  $M$  为  $2n \times 12$  矩阵， $x$  为 12 维向量。为简化求解过程，使用  $12 \times 12$  矩阵  $M^T M$  的零特征向量的加权和来表示解向量  $x$ ，这样得出权值  $\beta_i$  后即可得到方程组的解。

$$x = \sum_{k=1}^N \beta_k v_k$$

其中  $N$  为矩阵  $M^T M$  的零特征值数目， $v_i$  为矩阵的零特征向量。利用空间欧氏变换前后不同点之间的距离不变的特性，可对  $\beta_k$  进行求解。

$$\left\| \sum_{k=1}^N \beta_k v_k^{[i]} - \sum_{k=1}^N \beta_k v_k^{[j]} \right\|^2 = \|c_i^w - c_j^w\|^2$$

其中  $v_k^{[i]}$  为特征向量  $v_k$  中代表控制点  $c_i$  的子向量。

在得出特征向量权值  $\beta_k$  后即可计算出控制点的相机坐标  $c_j^c$ ，再通过开始时确定的控制点权值

$\alpha_{ij}$ , 即可得出参考点的相机坐标 $\mathbf{p}_i^c$ 。这样就将 2D-3D 位姿估计问题转化为 3D-3D 位姿估计问题, 可通过 ICP 等算法求解位姿。

为减小误差得到更高精度的解, 可以将之前求得的封闭解作为初值, 以特征向量权值 $\beta_k$ 作为优化变量, 以不同控制点的间距在欧氏变换前后的变化量作为误差, 通过 Gaussian-Newton 等方法, 进行迭代优化, 就得到了最大精度下的解。

## 二. 确定控制点坐标

理论上, 4 个控制点的坐标可任意选取。但是在 Lepetit 的论文中, 作者表示在实践中发现, 参考点的重心作为控制点之一时, 算法的结果较为稳定。首先, 将参考点的重心作为第一个控制点

$$\mathbf{c}_1^w = \frac{1}{n} \sum_{i=1}^n \mathbf{p}_i^w$$

之后构建矩阵 $\mathbf{A}$ ,  $\mathbf{A}$ 为 $n \times 3$ 矩阵。

$$\mathbf{A} = \begin{bmatrix} \mathbf{p}_1^{wT} - \mathbf{c}_1^{wT} \\ \vdots \\ \mathbf{p}_n^{wT} - \mathbf{c}_n^{wT} \end{bmatrix}$$

这样 $\mathbf{A}^T \mathbf{A}$ 为 $3 \times 3$ 矩阵, 3 个特征值分别为 $\lambda_1$ 、 $\lambda_2$ 和 $\lambda_3$ ; 3 个特征向量为 $\mathbf{v}_1$ 、 $\mathbf{v}_2$ 和 $\mathbf{v}_3$ 。那么控制点 $\mathbf{c}_2^w$ 、 $\mathbf{c}_3^w$ 和 $\mathbf{c}_4^w$ 为

$$\mathbf{c}_j^w = \mathbf{c}_1^w + \lambda_{j-1}^{\frac{1}{2}} \mathbf{v}_{j-1}$$

其中 $j = 2, 3, 4$ 。确定了 4 个控制点的世界坐标, 那么对应的控制点权值 $\alpha_{ij}$ 就很容易得到。

## 三. 求解控制点的相机坐标

在得到控制点的世界坐标后, 接下来就要通过矩阵 $\mathbf{M}$ 求解控制点的相机坐标。在参考点的 2D 像素坐标已知的情况下, 方程的解在矩阵 $\mathbf{M}$ 的核空间中。

### 3.1. 以特征向量的加权和表示控制点坐标

将相机坐标系和像素坐标系之间的转化关系展开为

$$s_i \begin{bmatrix} u_i \\ v_i \\ 1 \end{bmatrix} = \begin{bmatrix} f_u & 0 & u_0 \\ 0 & f_v & v_0 \\ 0 & 0 & 1 \end{bmatrix} \sum_{j=1}^4 \alpha_{ij} \begin{bmatrix} x_j^c \\ y_j^c \\ z_j^c \end{bmatrix}$$

在该式中, 4 个控制点的 12 个坐标值为未知量。将其转化为方程组的形式

$$\begin{aligned} s_i u_i &= \sum_{j=1}^4 \alpha_{ij} f_u x_j^c + \alpha_{ij} u_0 z_j^c \\ s_i v_i &= \sum_{j=1}^4 \alpha_{ij} f_v y_j^c + \alpha_{ij} v_0 z_j^c \\ s_i &= \sum_{j=1}^4 \alpha_{ij} z_j^c \end{aligned}$$

将最后一行代入前两行中, 可消去 $s_i$

$$\begin{aligned}\sum_{j=1}^4 \alpha_{ij} f_u x_j^c + \alpha_{ij} (u_0 - u_i) z_j^c &= 0 \\ \sum_{j=1}^4 \alpha_{ij} f_v y_j^c + \alpha_{ij} (v_0 - v_i) z_j^c &= 0\end{aligned}$$

这样，每一个参考点可以提供两个方程作为约束， $n$ 个参考点则能够提供 $2n$ 个方程。将方程组以矩阵的形式表示

$$\mathbf{M}\mathbf{x} = \mathbf{0}$$

其中 $\mathbf{M}$ 为 $2n \times 12$ 矩阵， $\mathbf{x}$ 为方程的未知数，为12维向量。

$$\mathbf{x} = [\mathbf{c}_1^{cT} \quad \mathbf{c}_2^{cT} \quad \mathbf{c}_3^{cT} \quad \mathbf{c}_4^{cT}]^T$$

易知，该方程组的解在 $\mathbf{M}$ 的零空间（核空间）内，也就是矩阵 $\mathbf{M}$ 的零奇异值所对应的奇异向量构成的线性空间内。而 $\mathbf{M}$ 的零奇异向量同时也是矩阵 $\mathbf{M}^T \mathbf{M}$ 的零特征向量。 $\mathbf{M}^T \mathbf{M}$ 是 $12 \times 12$ 矩阵，当 $n$ 的值很大时，计算 $\mathbf{M}^T \mathbf{M}$ 零特征向量的复杂度要远小于计算 $\mathbf{M}$ 零奇异向量；而计算 $\mathbf{M}^T \mathbf{M}$ 的复杂度为 $O(n)$ ，为整个计算过程中最耗时的步骤，同样远小于计算 $\mathbf{M}$ 零奇异向量的复杂度。因此，通过将方程组的解表示为 $\mathbf{M}^T \mathbf{M}$ 零特征向量加权的形式，可大大降低解算过程的计算量。即

$$\mathbf{x} = \sum_{k=1}^N \beta_k \mathbf{v}_k$$

其中 $\mathbf{v}_k$ 为 $\mathbf{M}^T \mathbf{M}$ 的零特征向量， $N$ 为 $\mathbf{M}^T \mathbf{M}$ 的零特征值数目（与参考点数目 $n$ 不同）， $\beta_k$ 为特征向量权值。

### 3.2. 求解合适的特征向量权值

在计算出矩阵 $\mathbf{M}^T \mathbf{M}$ 后，很容易求出其特征值，及对应的特征向量。在Lepetit的论文中提及， $N$ 的值与相机焦距有关。

当焦距较小时，适用透视相机模型，需要至少6对参考点，此时矩阵 $\mathbf{M}^T \mathbf{M}$ 的右零空间的维数恰好为1，即 $N = 1$ 。

焦距较大时，适用正交相机模型，改变控制点深度对参考点的投影没有影响，此时 $N = 4$ 。由于所提供对应的参考点坐标常常带有噪声，因此矩阵的4个零特征值在实际运算中并不严格为零，会有微小的值。

Lepetit的论文中提及， $N$ 的取值可以为1~4的整数，由参考点的配置、相机焦距、噪声数量等因素决定。为避免特征值过于接近而导致的在选取 $N$ 的值时出现的错误，Lepetit在文中建议将 $N = 1 \sim 4$ 时的权值全部计算出，并在结果中选取重投影误差最小的一项。这一方法在参考点提供的约束不足时仍然适用。

$$\text{res} = \sum_i \text{dist}^2 \left( \mathbf{K}[\mathbf{R}|\mathbf{t}] \begin{bmatrix} \mathbf{p}_i^w \\ 1 \end{bmatrix}, \mathbf{u}_i \right)$$

相比于计算 $\mathbf{M}^T \mathbf{M}$ ，计算重投影误差所需的计算量非常小，却大大加强了算法的鲁棒性。在计算特征向量权值时，可利用空间欧氏变换前后不同点之间的距离不变的特性列出方程，对 $\beta_i$ 进行求解。

$$\left\| \sum_{k=1}^N \beta_k \mathbf{v}_k^{[i]} - \sum_{k=1}^N \beta_k \mathbf{v}_k^{[j]} \right\|^2 = \|\mathbf{c}_i^w - \mathbf{c}_j^w\|^2$$

其中 $\mathbf{v}_k^{[i]}$ 为特征向量 $\mathbf{v}_k$ 中代表控制点 $\mathbf{c}_i$ 的子向量。接下来讨论在 $N$ 的不同取值下，求解 $\beta_k$ 的不

同方法。

当  $N = 1$  时，仅有 1 个  $\beta$ 。此时可列出方程

$$\|\beta \mathbf{v}^{[i]} - \beta \mathbf{v}^{[j]}\|^2 = \|\mathbf{c}_i^w - \mathbf{c}_j^w\|^2$$

则  $\beta$  的封闭解为

$$\beta = \frac{\sum_{\{i,j\} \in [1,4]} \|\mathbf{v}^{[i]} - \mathbf{v}^{[j]}\| \cdot \|\mathbf{c}_i^w - \mathbf{c}_j^w\|}{\sum_{\{i,j\} \in [1,4]} \|\mathbf{v}^{[i]} - \mathbf{v}^{[j]}\|^2}$$

当  $N = 2$  时，有  $\beta_1$ 、 $\beta_2$

$$\mathbf{x} = \beta_1 \mathbf{v}_1 + \beta_2 \mathbf{v}_2$$

可列出方程

$$\|(\beta_1 \mathbf{v}_1^{[i]} + \beta_2 \mathbf{v}_2^{[i]}) - (\beta_1 \mathbf{v}_1^{[j]} + \beta_2 \mathbf{v}_2^{[j]})\|^2 = \|\mathbf{c}_i^w - \mathbf{c}_j^w\|^2$$

这是一个关于  $\beta$  的二次方程，为便于计算，以线性化的方式进行求解。以  $\beta_{12}$  代替  $\beta_1 \beta_2$ ， $\beta_{11}$  代替  $\beta_1^2$ ， $\beta_{22}$  代替  $\beta_2^2$ ，这样方程即可改为求解  $[\beta_{11} \ \beta_{12} \ \beta_{22}]^T$ 。就 4 个控制点而言，由  $i, j$  的不同取值，共有  $C_4^2 = 6$  个方程，因此用矩阵表示方程组为

$$\mathbf{L}\boldsymbol{\beta} = \boldsymbol{\rho}$$

其中  $\mathbf{L}$  为  $6 \times 3$  系数矩阵， $\boldsymbol{\beta}$  为 3 维未知数向量， $\boldsymbol{\rho}$  为 6 维向量，表示控制点间距离。可通过  $\mathbf{L}$  的伪逆来求解  $\beta_{ab}$  的值；之后可通过参考点的深度为正的规律，确定  $\beta_a$  的符号；进而得出  $\beta_a$  的值，求得每个控制点的坐标。

当  $N = 3$  时，有  $\beta_1$ 、 $\beta_2$ 、 $\beta_3$ 。与  $N = 2$  的情况类似，将二次方程线性化后，求解向量  $\boldsymbol{\beta}$ 。此时  $\boldsymbol{\beta}$  为 6 维向量

$$\boldsymbol{\beta} = [\beta_{11} \ \beta_{12} \ \beta_{13} \ \beta_{22} \ \beta_{23} \ \beta_{33}]^T$$

而  $\mathbf{L}$  则为  $6 \times 6$  矩阵。此时可通过  $\mathbf{L}$  的逆矩阵求解  $\boldsymbol{\beta}$ ，进而得出每个控制点的坐标。

当  $N = 4$  时，有  $\beta_1$ 、 $\beta_2$ 、 $\beta_3$ 、 $\beta_4$ ，线性化后  $\boldsymbol{\beta}$  为 10 维未知数向量。那么 6 个方程的约束不足以直接解出 10 个未知数。此时考虑到乘法的交换性

$$\beta_{ab}\beta_{cd} = \beta_a\beta_b\beta_c\beta_d = \beta_{a'b'}\beta_{c'd'}$$

其中  $\{a', b', c', d'\}$  为  $\{a, b, c, d\}$  的另一种排列方式。这样可以减小未知数的个数，例如

$$\beta_{23} = \frac{\beta_{12}\beta_{13}}{\beta_{11}}$$

如此，可解出  $\boldsymbol{\beta}$ ，进而得出每个控制点的坐标。

### 3.3. 平面情况下的求解方法

在平面情况下，所有的参考点都位于同一平面上，此时只需要 3 个控制点， $\mathbf{M}$  为  $2n \times 9$  矩阵。 $\mathbf{M}^T \mathbf{M}$  的特征向量也相应地变为 9 维，但是上文所提及的关于矩阵  $\mathbf{M}$  的约束依然有效，只是方程数目从 6 个减为 3 个。因此，在  $N \geq 3$  时，就需要使用之前非平面形式下在  $N = 4$  时才需要用到的减小未知数个数的方法。

## 四. Gaussian-Newton 优化

在前文得出  $\boldsymbol{\beta}$  的封闭解的基础上，以之作为初值，将  $\boldsymbol{\beta} = [\beta_1 \ \beta_2 \ \beta_3 \ \beta_4]^T$  作为优化变量，以不同控制点的间距在欧氏变换前后的变化量作为误差，可得出目标函数

$$\text{Error}(\boldsymbol{\beta}) = \sum_{(i,j) \text{ s.t. } i < j} (\|\mathbf{c}_i^c - \mathbf{c}_j^c\|^2 - \|\mathbf{c}_i^w - \mathbf{c}_j^w\|^2)$$

这是一个无约束的非线性最优化问题，使用 Gaussian-Newton 法求解即可。此时优化变量仅限于  $\boldsymbol{\beta}$ ，最多不超过 4 个，与参考点数目无关，因此优化过程中的计算量极低，可视作常数。一般情况下，这一步骤的优化迭代次数不会超过 10 次。计算封闭解与优化的整体复杂

度可视为与参考点数目呈线性关系。

在优化得出最优解后，即可计算出参考点在相机坐标系下的坐标 $\mathbf{p}_i^c$ ，将 2D-3D 位姿估计问题转化为 3D-3D 位姿估计问题。之后求解位姿即可（可通过 ICP 等算法）。

## 参考

- [1] Lepetit V, Moreno-Noguer F, Fua P. EPnP: An Accurate  $O(n)$  Solution to the PnP Problem[J]. International Journal of Computer Vision, 2009, 81(2): 155.
- [2] JesseChen79.深入 EPnP 算法[EB/OL]. <https://blog.csdn.net/jessecw79/article/details/82945918>, 2018-10-5.
- [3] 袁酱.理解 EPnP 算法[EB/OL]. <https://blog.csdn.net/u010821666/article/details/80738359>, 2018-8-14.