

# 对极几何与三角测量整理

对于同一相机从不同角度拍摄的两幅图像，对其进行特征提取和匹配，就得到了若干对匹配特征；根据这些图像中二维坐标点的匹配关系，就可以恢复出两幅图像间摄像机的旋转和平移（即位姿的变化）。这是一个 2D 点对（即 2D-2D）间的运动估计问题，通常使用对极几何的方式得到相机相对运动的位姿。在 SLAM 实际应用中，通常被用于单目相机的初始化、双目相机的标定等方面。

## 一、 基本思想

如图 1，两个视角下的摄像机光心分别为 $O_1$ 和 $O_2$ ，图像所在的平面分别为 $I_1$ 和 $I_2$ ，三维空间中的点 $P$ 在两幅图像的投影分别为 $p_1$ 和 $p_2$ ，连接点 $P$ 、 $O_1$ 和 $O_2$ 所构成的平面为极平面（Epipolar plane），而连线 $O_1O_2$ 则称为基线（Baseline），基线与成像平面的交点 $e_1$ 、 $e_2$ 为极点（Epipoles），连线 $p_1e_1$ 、 $p_2e_2$ （即极平面与两个成像平面的交线）可记作 $l_1$ 、 $l_2$ ，称为极线（Epipolar line）。这样的几何约束关系称为对极几何约束。




图 1 对极几何约束

我们可以通过这些点的共面关系恢复出摄像机间的相对位姿 $R$ 、 $t$ 。

而另一方面，由于极平面的存在，一幅图像中的特征的对应匹配点必然会出现另一幅图的对应极线中。因此，在已经确定位姿关系的两幅图像中，匹配特征不必在整幅图像中搜索对应点，只需在对应的极线上搜索即可，这样就将二维搜索转化为一维搜索，在双目视觉 SLAM 中借助这一特性，可大大降低双目特征匹配时的计算量，同时也可提高特征匹配的准确率。

## 二、 基础矩阵和本征矩阵

两幅图像的位姿关系可由本征矩阵（Essential Matrix） $E$ 表述，本征矩阵仅包含二者之间的位姿信息；而基础矩阵（Fundamental Matrix） $F$ 则在位姿信息的基础上包含了摄像机的内参数 $K$ 。本征矩阵在归一化的物理坐标系下操作，而基础矩阵在图像坐标系下进行操作。接下来从数学角度对 $E$ 和 $F$ 进行推导。

### 2.1 本征矩阵

已知三维空间中的点 $P = (X, Y, Z)^T$ （在第一帧坐标系下），该点在两幅图像的投影分别为 $p_1$ 和 $p_2$ ，则有

$$sp_1 = KP$$

$$sp_2 = K(RP + t)$$

取两个像素点 $p_1$ 、 $p_2$ 的归一化平面坐标为 $x_1$ 和 $x_2$ ，那么

$$x_1 = K^{-1}p_1$$

$$\mathbf{x}_2 = \mathbf{K}^{-1}\mathbf{p}_2$$

代入之后则有

$$\mathbf{x}_2 = \mathbf{R}\mathbf{x}_1 + \mathbf{t}$$

移项得

$$\mathbf{x}_2 - \mathbf{t} = \mathbf{R}\mathbf{x}_1$$

对于同一平面上的向量 $\mathbf{x}$ 和 $\mathbf{a}$ ，以及该平面的法向量 $\mathbf{n}$ ，有约束条件

$$\mathbf{n} \cdot (\mathbf{x} - \mathbf{a}) = 0$$

而 $\mathbf{x}_2$ 和 $\mathbf{t}$ 都在极平面内，取 $\mathbf{t} \times \mathbf{x}_2$ 为法向量，那么

$$(\mathbf{t} \times \mathbf{x}_2)^T (\mathbf{x}_2 - \mathbf{t}) = 0$$

代入

$$(\mathbf{t} \times \mathbf{x}_2)^T \mathbf{R}\mathbf{x}_1 = 0$$

化为反对称矩阵

$$([\mathbf{t}]_{\times} \mathbf{x}_2)^T \mathbf{R}\mathbf{x}_1 = 0$$

括号内展开

$$\mathbf{x}_2^T [\mathbf{t}]_{\times}^T \mathbf{R}\mathbf{x}_1 = 0$$

$$-\mathbf{x}_2^T [\mathbf{t}]_{\times} \mathbf{R}\mathbf{x}_1 = 0$$

去掉负号

$$\mathbf{x}_2^T [\mathbf{t}]_{\times} \mathbf{R}\mathbf{x}_1 = 0$$

最终可得到

$$\mathbf{x}_2^T \mathbf{E} \mathbf{x}_1 = 0$$

即本征矩阵 $\mathbf{E}$ 为

$$\mathbf{E} = [\mathbf{t}]_{\times} \mathbf{R}$$

由 $\text{rank}([\mathbf{t}]_{\times}) = 2$ 易知， $\mathbf{E}$ 的秩为 2，同样是秩亏矩阵； $[\mathbf{t}]_{\times}$ 为反对称矩阵， $\mathbf{R}$ 为正交矩阵，因此 $\mathbf{E}$ 的两个非零特征值相等。

由于对极约束是等于 0 的等式，因此对于 $\mathbf{E}$ 而言，乘以任意非零常数后性质不变，因此 $\mathbf{E}$ 具有尺度不确定性。

而另一方面，得到矩阵 $\mathbf{E}$ 的两个分量平移 $\mathbf{t}$ 和旋转 $\mathbf{R}$ 都具有 3 自由度，共 6 自由度，再由于其尺度不确定性去掉 1 自由度，可知 $\mathbf{E}$ 共有 5 自由度。

## 2.2 基础矩阵

令单应性矩阵 $\mathbf{H}_{3 \times 4} = \mathbf{K}[\mathbf{R} \mid \mathbf{t}]$ ，则有

$$\mathbf{s}\mathbf{p}_1 = \mathbf{H}_1 \mathbf{P}$$

$$\mathbf{s}\mathbf{p}_2 = \mathbf{H}_2 \mathbf{P}$$

其中

$$\mathbf{H}_1 = \mathbf{K}[\mathbf{I} \mid \mathbf{0}]$$

$$\mathbf{H}_2 = \mathbf{K}[\mathbf{R} \mid \mathbf{t}]$$

显然 $\text{rank } \mathbf{H} = 3$ ，那么矩阵 $\mathbf{H}$ 的核空间（即右零空间）为一维空间，即

$$\mathbf{H} \cdot \mathbf{C} = \mathbf{0}$$

其中 $\mathbf{C}$ 为 $4 \times 1$ 向量，可视作由齐次坐标表示的三维空间中的一点。

以 $\mathbf{C}$ 为原点，与 $\mathbf{P}$ 可确定一条射线，射线上的点 $\mathbf{P}(\lambda)$ 可表示为（其中 $\lambda$ 为比例系数）

$$\mathbf{P}(\lambda) = \lambda \mathbf{P} + (1 - \lambda) \mathbf{C}$$

故

$$\mathbf{p}(\lambda) = \lambda \mathbf{H}_1 \mathbf{P} + (1 - \lambda) \mathbf{H}_1 \mathbf{C}$$

$$= \lambda \mathbf{H}_1 \mathbf{P}$$

$$= \mathbf{p}_1$$

也就是说，射线 $\mathbf{CP}$ 上所有的点在第一幅图像上的投影都与点 $\mathbf{P}$ 的投影 $\mathbf{p}_1$ 重合，故而易知该射线通过摄像机 1 的光心；而点 $\mathbf{P}$ 为空间中任意点，点 $\mathbf{C}$ 是该射线上唯一固定点，可知点 $\mathbf{C}$ 是摄像机 1 的光心 $\mathbf{O}_1$ 。

反之，可求得通过光心 $\mathbf{C}$ 和点 $\mathbf{p}_1$ 的射线上的点可表示为

$$\mathbf{Q}(\lambda) = \mathbf{H}_1^+ \mathbf{p}_1 + \lambda \mathbf{C}$$

其中 $\mathbf{H}_1^+$ 为单应性矩阵的伪逆。

取该射线上两点 $\mathbf{H}_1^+ \mathbf{p}_1$ 和 $\mathbf{C}$ ，分别投影到第二幅视图上，即为 $\mathbf{H}_2 \mathbf{H}_1^+ \mathbf{p}_1$ 和 $\mathbf{H}_2 \mathbf{C}$ ，由之前的条件易知 $\mathbf{H}_2 \mathbf{C}$ 即为第二幅视图上的极点 $\mathbf{e}_2$ ， $\mathbf{H}_2 \mathbf{H}_1^+ \mathbf{p}_1$ 在极线 $\mathbf{l}_2$ 上，故而极线 $\mathbf{l}_2$ 为

$$\begin{aligned} \mathbf{l}_2 &= \mathbf{e}_2 \times \mathbf{H}_2 \mathbf{H}_1^+ \mathbf{p}_1 \\ &= [\mathbf{e}_2]_{\times} \mathbf{H}_2 \mathbf{H}_1^+ \mathbf{p}_1 \end{aligned}$$

而点 $\mathbf{p}_2$ 也在极线 $\mathbf{l}_2$ 上，则有

$$\mathbf{p}_2^T \mathbf{l}_2 = 0$$

故

$$\mathbf{p}_2^T [\mathbf{e}_2]_{\times} \mathbf{H}_2 \mathbf{H}_1^+ \mathbf{p}_1 = 0$$

即

$$\begin{aligned} \mathbf{p}_2^T \mathbf{F} \mathbf{p}_1 &= 0 \\ \mathbf{F} &= [\mathbf{e}_2]_{\times} \mathbf{H}_2 \mathbf{H}_1^+ \end{aligned}$$

将

$$\begin{aligned} \mathbf{H}_1 &= \mathbf{K}[\mathbf{I} \mid \mathbf{0}] \\ \mathbf{H}_2 &= \mathbf{K}[\mathbf{R} \mid \mathbf{t}] \\ \mathbf{H}_1^+ &= \begin{bmatrix} \mathbf{K}^{-1} \\ \mathbf{0}^T \end{bmatrix} \\ \mathbf{C} &= \begin{bmatrix} \mathbf{0} \\ 1 \end{bmatrix} \end{aligned}$$

等代入，进而求出

$$\begin{aligned} \mathbf{e}_2 &= \mathbf{H}_2 \mathbf{C} \\ &= \mathbf{K}[\mathbf{R} \mid \mathbf{t}] \begin{bmatrix} \mathbf{0} \\ 1 \end{bmatrix} \\ &= \mathbf{K} \mathbf{t} \end{aligned}$$

及

$$\begin{aligned} \mathbf{F} &= [\mathbf{e}_2]_{\times} \mathbf{H}_2 \mathbf{H}_1^+ \\ &= [\mathbf{K} \mathbf{t}]_{\times} [\mathbf{R} \mid \mathbf{t}] \begin{bmatrix} \mathbf{K}^{-1} \\ \mathbf{0}^T \end{bmatrix} \\ &= [\mathbf{K} \mathbf{t}]_{\times} \mathbf{K} \mathbf{R} \mathbf{K}^{-1} \\ &= \mathbf{K}^{-T} [\mathbf{t}]_{\times} \mathbf{K}^{-1} \mathbf{K} \mathbf{R} \mathbf{K}^{-1} \\ &= \mathbf{K}^{-T} [\mathbf{t}]_{\times} \mathbf{R} \mathbf{K}^{-1} \end{aligned}$$

即，基础矩阵 $\mathbf{F}$ 为

$$\mathbf{F} = \mathbf{K}^{-T} [\mathbf{t}]_{\times} \mathbf{R} \mathbf{K}^{-1}$$

或

$$\mathbf{F} = \mathbf{K}^{-T} \mathbf{E} \mathbf{K}^{-1}$$

与本征矩阵类似，基础矩阵同样具有尺度不确定的特性，即矩阵相乘一个非零常数之后不影响结果； $\text{rank}(\mathbf{F}) = 2$ ，但是 $\mathbf{F}$ 的两个非零特征值不相等。由

$$\mathbf{F} = [\mathbf{e}_2]_{\times} \mathbf{H}_2 \mathbf{H}_1^+$$

其中 $\mathbf{H}_2 \mathbf{H}_1^+$ 可视作单应变换 $\mathbf{H}_{\pi}$ ，有 8 自由度，而 $\text{rank}(\mathbf{F}) = 2$ ，为 $\mathbf{F}$ 增加了一个约束，因此 $\mathbf{F}$

有 7 自由度。

### 三、 求解基础矩阵

相比于本征矩阵，基础矩阵的约束是针对匹配点对的像素坐标的，相对而言更易获得，因此更多使用基础矩阵来估计两幅视角的位姿变化。由于基础矩阵  $\mathbf{F}$  具有 7 自由度，所以理论上通过 7 对对应点就可以解出  $\mathbf{F}$ ，但是这一算法是基于  $\mathbf{F}$  秩为 2 的约束下的，共有 3 组不同的解。由于实际的图像中会有至少几十对匹配的特征，因此使用 7 点法的意义不大，更多的还是采用八点法的方式，通过线性方程组求解基础矩阵。而当所提供的匹配对数超过八对时，则可以求其最小二乘解。在 OpenCV 的相关函数中，除了 7 点算法和 8 点算法外，为增强算法的鲁棒性，还提供了 RANSAC、LMedS 等选项。

接下来简单介绍一下八点法求解基础矩阵  $\mathbf{F}$  的算法。假设有一对匹配的特征，他们的坐标分别为

$$\begin{aligned}\mathbf{p}_1 &= [u_1 \quad v_1 \quad 1]^T \\ \mathbf{p}_2 &= [u_2 \quad v_2 \quad 1]^T\end{aligned}$$

用  $f_i$  表示  $\mathbf{F}$  中的每个元素，那么基础矩阵的约束关系可以表示为

$$[u_1 \quad v_1 \quad 1] \begin{bmatrix} f_1 & f_2 & f_3 \\ f_4 & f_5 & f_6 \\ f_7 & f_8 & f_9 \end{bmatrix} \begin{bmatrix} u_2 \\ v_2 \\ 1 \end{bmatrix} = 0$$

将  $\mathbf{F}$  展开为向量

$$\mathbf{f} = [f_1 \quad f_2 \quad f_3 \quad f_4 \quad f_5 \quad f_6 \quad f_7 \quad f_8 \quad f_9]^T$$

那么等式可以化为

$$[u_1 u_2 \quad u_1 v_2 \quad u_1 \quad v_1 u_2 \quad v_1 v_2 \quad v_1 \quad u_2 \quad v_2 \quad 1] \cdot \mathbf{f} = 0$$

对于其他的匹配特征也采用同样的方法表示，将所有方程放到一起，可得到一个线性方程组（其中  $u^i$ 、 $v^i$  表示第  $i$  对匹配特征的坐标）

$$\begin{bmatrix} u_1^1 u_2^1 & u_1^1 v_2^1 & u_1^1 & v_1^1 u_2^1 & v_1^1 v_2^1 & v_1^1 & u_2^1 & v_2^1 & 1 \\ u_1^2 u_2^2 & u_1^2 v_2^2 & u_1^2 & v_1^2 u_2^2 & v_1^2 v_2^2 & v_1^2 & u_2^2 & v_2^2 & 1 \\ u_1^3 u_2^3 & u_1^3 v_2^3 & u_1^3 & v_1^3 u_2^3 & v_1^3 v_2^3 & v_1^3 & u_2^3 & v_2^3 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ u_1^8 u_2^8 & u_1^8 v_2^8 & u_1^8 & v_1^8 u_2^8 & v_1^8 v_2^8 & v_1^8 & u_2^8 & v_2^8 & 1 \end{bmatrix} \begin{bmatrix} f_1 \\ f_2 \\ f_3 \\ f_4 \\ f_5 \\ f_6 \\ f_7 \\ f_8 \\ f_9 \end{bmatrix} = \mathbf{0}$$

求解该方程组即可得到  $\mathbf{F}$  中各个参数的解。若该方程大于 8 行，即多于 8 组匹配的特征，则求其最小二乘解。

在实际计算中，由于噪声、数值舍入等原因造成误差，常常导致求出的基础矩阵不稳定。因此在解方程之前，先对匹配的坐标进行归一化，之后再行计算。

在 OpenCV 中使用的是各向同性归一化算法，即归一化之后各点到坐标原点的距离是  $\sqrt{2}$ ，线性变换的过程为

$$\begin{aligned}\mathbf{p}'_1 &= \mathbf{T}_1 \mathbf{p}_1 \\ \mathbf{p}'_2 &= \mathbf{T}_2 \mathbf{p}_2\end{aligned}$$

由  $\mathbf{p}'_1$  和  $\mathbf{p}'_2$ （以及很多对其他对应点）求出解，得到  $\mathbf{F}'$ ，进而将其还原为基础矩阵  $\mathbf{F}$

$$\mathbf{F} = \mathbf{T}_2^T \mathbf{F}' \mathbf{T}_1$$

由之前的推导过程易知，第一幅视图中的每一点在第二幅视图中都有不同的极线与之对应， $\mathbf{p}_1$  所对应的极线  $\mathbf{l}_2$  为

$$l_2 = Fp_1$$

在 OpenCV 的计算极线的函数中，输出的极线以 $(a, b, c)$ 的形式进行编码，并且在输出前将其归一化，使得 $a^2 + b^2 = 1$ 。

## 四、三角测量

三角测量作为一种历史悠久的距离估算方法，广泛应用于航海、天文、测绘等领域。在得到相机的相对运动之后，可以使用这一方法，结合位姿来计算特征的深度，或者说是特征在空间中的三维坐标信息。




图 2 三角测量求取特征深度

如图 2，已知点的像素坐标 $p_i$ 、相机内参 $K$ 、以及摄像机相对位姿 $R$ 和 $t$ ，理论上直线 $O_1p_1$ 和 $O_2p_2$ 在场景中会与点 $P$ 相交，但是由于噪声的影响，两条直线往往无法相交。暂时不考虑误差，可以列出方程

$$s_1 K^{-1} p_1 = s_2 R K^{-1} p_2 + t$$

由像素坐标 $p_i$ 和相机内参 $K$ ，可以得出归一化坐标 $x_i$

$$p_i = K x_i$$

方程可化简为

$$s_1 x_1 = s_2 R x_2 + t$$

其中 $s_i$ 是方程的未知数，即需要计算的特征在相机坐标系下的深度（Z坐标），在两侧同时左乘 $x_1^T$ 的反对称矩阵 $x_1^\wedge$

$$s_1 x_1^\wedge x_1 = s_2 x_1^\wedge R x_2 + x_1^\wedge t$$

这样方程左侧为 0，可以直接求出 $s_2$ 的值，进而 $s_1$ 的值也很容易求出。

在实际应用中，由于误差的存在，一般很难求出其精确解，因此常常会求其最小二乘解。




图 3 三角测量的矛盾

如图 3，三角测量的一个很重要的存在前提就是平移，如果没有平移，三角形无法成立，三角测量也就无从谈起了。而对于三角形而言，**增大平移**使得同样的角度误差 $\delta\theta$ 下的深度误差 $\delta d$ 更小，即三角测量**更加精确**。但是与此矛盾的是，增大平移的同时也会使得视角变化较大，摄像机采集到的图像因而产生较大的变化，造成**特征匹配困难**。这就是三角测量中存在的矛盾：大平移量易导致匹配失效，而小平移量易导致较大误差。

## 参考

- [1] 高翔, 张涛, 刘毅, 等. 视觉 SLAM 十四讲[M]. 北京: 电子工业出版社, 2017.
- [2] Kaehler A, Bradski G. 学习 OpenCV3[M]. 阿丘科技团队, 译. 北京: 清华大学出版社, 2018.
- [3] Hartley R, Zisserman A. 计算机视觉中的多视图几何[M]. 韦穗, 杨尚骏等, 译. 合肥: 安徽大学出版社, 2002.
- [4] kokerf. 基本矩阵的基本解法之 8 点算法[EB/OL]. 2017[2019-3-7]. <https://blog.csdn.net/kokerf/article/details/72630863>.
- [5] Brook\_icv. SLAM 入门之视觉里程计(4): 基础矩阵的估计[EB/OL]. 2018[2019-3-7]. <https://www.cnblogs.com/wangguchangqing/p/8214032.html>.
- [6] 语冰. 为什么本质矩阵 5 自由度, 基础矩阵 7 自由度, 单应矩阵 8 自由度? [EB/OL]. 2018[2019-3-7]. <https://www.zhihu.com/question/270431743>.